

Relatório 6 - Vídeo: O Que É Ciência De Dados (I)

Matheus Beuren Carvalho

1. Introdução

A tarefa designada, foi assistir os vídeos referentes à data science ou em português ciência de dados. O principal objetivo deste relatório é mostrar os principais conhecimentos aprendidos e mostrar o que realmente é ciência de dados segundo os vídeos do card.

2. Desenvolvimento

O princípio de data science começou lá atrás onde em meio às guerras aviões que retornavam para base eram analisados e decididos onde era os melhores lugares para se colocar blindagem em um avião, aí surgiu a análise de Wald.

Segundo o Vídeo (O que é ciência de dados | Nerdologia Tech), estamos na transição entre entender e analisar os dados, e usar essa análise com algoritmos para prever algo, o exemplo citado foi de Newton onde ele pega a análise já feita do sistema solar e faz uma fórmula para dizer o que está acontecendo e por que, exatamente o que machine learning pode fazer, não em um sentido de explicar com palavras, mas sim a análise dos dados preditivos.

Agora, com a era do Machine Learning, o modelo pode ter acesso aos dados e reconhecer padrões e fazer análises que podem acontecer no futuro(predição).

Hoje a maioria dos dados não são estruturados, como os dados vindos de satélites e de máquinas, por exemplo, pois eles descrevem como está o funcionamento, como está o sistema. Então, é necessário que seja feita uma limpeza e organização dos dados, (engenharia de dados) onde é feita a transformação do conjunto de dados. Nisso, dados ruins fazem análises ruins, e dados ruins constroem um modelo errado fazendo assim, uma análise totalmente errada.


No segundo vídeo(O que realmente é Ciência de Dados? Explicado por um Cientista de Dados), é um vídeo mais direto ao ponto, onde o cientista fala sobre data science e qual o real impacto dela hoje. Data science não é só fazer modelos difíceis, mas é usar os dados para causar maior impacto na empresa.

O objetivo de um Cientista de Dados é usar os dados para resolver problemas reais, e não somente fazer modelos preditivos, análises gigantes e gráficos bonitos. O real impacto de um cientista de dados está na resolução de problemas reais usando os dados.

Joma, Cientista de Dados do vídeo em questão, destaca que há uma diferença entre o que falam sobre a profissão na internet e o que ela realmente é para as empresas, onde seu verdadeiro foco para as empresas é vender mais, melhorar seus produtos e gerar lucro.

Dando continuidade ao vídeo, Joma explica onde, quando e como começou a ciência de dados, passando por momentos históricos até a apresentação do machine learning e como foi criada também levemente citada o deep learning.


Em seguida, a imagem da pirâmide do vídeo, (Figura 1).



Esta pirâmide mostra a hierarquia do que um cientista de dados precisa. A base da pirâmide é a Coleta, que representa os dados brutos, aqueles que vêm de algum sensor, algum aplicativo ou qualquer outra fonte de dados, isso é muito importante pois sem essa base nada pode ser feito depois. Depois da coleta, temos que guardar esses dados de forma organizada, seja em um banco de dados ou data lake. A transformação, terceira camada, é onde tratamos os dados, onde ocorre a limpeza de dados, ou seja a preparação dos dados para as próximas etapas. A quarta camada, é feita a seleção de features, separar dados de treino e dados de teste, transformar os dados em informações úteis, rotular dados, entre outras

etapas. Em Otimização, ocorrem treinos com modelos simples e testes A/B. Na última camada, é aplicado modelos grandes e análises de suas predições, mas para isso acontecer todas as etapas anteriores tem que ser sólidas e confiáveis, se não, pode ocasionar o treino em modelos e análises ruins.

A seguir na figura 2, um pipeline ETL e treino de um modelo, muito utilizado atualmente pelos cientistas de dados.



3. Conclusão

Concluindo este relatório, foi aprendido os conteúdos abordados nos dois vídeos designados no card. Nos dois vídeos, o principal foco é a ciência de dados, o primeiro vídeo(O que é ciência de dados | Nerdologia Tech) aborda conteúdos mais básicos e a introdução para o data science de uma forma eficiente, já o segundo vídeo(O que realmente é Ciência de Dados? Explicado por um Cientista de Dados) aborda um conteúdo mais profundo de ciência de dados, onde mostra o que ser um cientista de dados, quais suas tarefas e sua importância para o mercado, o impacto causado pelos dados em empresas.