

Relatório 8 - Prática: Web Scraping com Python p/ Ciência de Dados (II)

Matheus Beuren Carvalho

1. Introdução

No card 8, foi designado a visualização de um vídeo que ensina web scraping por meio do python. Usando somente duas bibliotecas é possível coletar e manipular dados em HTML, extraíndo informações estruturadas de páginas web.

2. Desenvolvimento

Inicialmente, o vídeo apresenta o que é web scraping e dá uma leve introdução ao HTML. Onde por sua vez, mostra o conceito principal do scraping, coleta de dados de uma página web por meio do html, que é muito útil para coletar dados e montar um treino de ML, pegar cotações diárias, entre muitas outras funcionalidades. O HTML é uma linguagem de marcação de hipertexto, parte mais básica de desenvolvimento web.

Em seguida, damos início a parte de fazer scraping com python. Começando por fazer a coleta dos dados HTML para o python, o instrutor utiliza funções básicas de busca para procurar na base da coleta HTML, podendo utilizar parâmetros e fazer busca com strings.

Mais alguns comandos úteis, é a busca por meio de caminho, atribuindo “.” para passar para o filho e assim sucessivamente. Isso facilita muito a busca pois, em certas ocasiões poupa a utilização do find caso você saiba a estrutura do código em html. Na mesma aula, o vídeo mostra o re.compile(), método que busca um padrão em strings.

Uma das partes mais interessantes, é a possibilidade de selecionar e filtrar com base em css. Nesse tipo de seleção, pode-se atribuir tanto uma classe, id ou atributo com seu nome em questão. Além disso, tem como selecionar uma tag a partir de outra, pegando o filho direto, ou irmãos anteriores, exemplos mostrados pelo vídeo.

Segundo o vídeo, existem duas formas de pegar o texto de um elemento, utilizando o “.string” que pega o texto do elemento selecionado, e o “get_text()” que pega o texto do elemento e o de seus filhos. No mesmo contexto, o instrutor mostra o acesso por meio de atributos, utilizando como exemplo a tag “a” que tem um link, para conseguir pegar somente o link é feito ‘link[“href”]’.

Menciono um dos pontos que vejo como o principal uso deste método, que é a coleta de dados de uma página como mostrado no vídeo, porém agora filtrando e


selecionando os dados para colocá-los em um Data Frame, coisa que também o vídeo aborda mais de uma forma mais introdutória. Após essa transformação, a criação de um dataset é inevitável e com isso podendo ser utilizado para pipelines de Ciência de Dados e treinos de Machine Learning.

O web scraping, pode ser utilizado de diversas maneiras diferentes, pois a possibilidade de coletar dados da web cria diversos caminhos e facilita o uso de dados para diferentes causas, seja dentro de uma empresa ou análise de um problema. Nisso, o scraping atua como uma ferramenta de coleta muito importante, podendo ser automatizada por pipelines de automação, como por exemplo, o airflow, que agendará o scraping para ser executado e coletar dados da web, assim colocando-o em uma posição muito importante em ciencia de dados.

Alguns exemplos de seu uso, são a análise de preço de possíveis concorrentes de lojas comerciais, coleta de notícias em jornais e portais, coleta de preços para um aplicativo de recomendação de preços baixos e entre outras diversas formas de usar este método.

Na figura 1, é apresentado um exemplo real de como pode ser utilizado web scraping.

Figura 1



3. Conclusão

Esta aula, teve o intuito de conhecer e praticar com o web scraping, um método de coleta de dados através do HTML de um site web. Vejo o scraping em um modo de automatizar a coleta de dados, nisso, vejo uma grande utilização em lugares que seriam necessarios coletar dados manualmente de forma repetitiva, como cotações e preços, substituindo esta coleta manual por uma automatizada utilizando o web scraping e o airflow.