

Relatório 8 - Prática: Web Scraping com Python p/ Ciência de Dados (II)

Matheus Beuren Carvalho

1. Introdução

No card 8, foi designado a visualização de um vídeo que ensina web scraping por meio do python. Usando somente duas bibliotecas, o instrutor ensina como pegar e como manipular os dados em html por meio dessas duas bibliotecas.

2. Desenvolvimento

No início do vídeo, o instrutor nos apresenta o que é web scraping e uma leve introdução ao html. Onde por sua vez, mostra o conceito principal do scraping, coleta de dados de uma página web por meio do html, que é muito útil para coletar dados e montar um treino de ML, pegar cotações diárias, entre muitas outras funcionalidades. O html é uma linguagem de marcação de hipertexto, parte mais básica de desenvolvimento web.

Em seguida, damos início a parte de fazer scraping com python. Começando por fazer a coleta dos dados html para o python, o instrutor utiliza funções básicas de busca para procurar na base da coleta html, podendo utilizar parâmetros e fazer busca com strings.

Mais alguns comandos úteis, é a busca por meio de caminho, atribuindo “.” para passar para o filho e assim sucessivamente. Isso facilita muito a busca pois, em certas ocasiões poupa a utilização do find caso você saiba a estrutura do código em html.

Na mesma aula, o instrutor mostra o `re.compile()`, método que busca um padrão em strings.


Uma das partes mais interessantes, é a possibilidade de selecionar e filtrar com base em css. Nesse tipo de seleção, pode-se atribuir tanto uma classe, id ou atributo com seu nome em questão. Além disso, tem como selecionar uma tag a partir de outra, pegando o filho direto, ou irmãos anteriores, exemplos mostrados pelo instrutor.

Segundo o vídeo, existem duas formas de pegar o texto de um elemento, utilizando o “`.string`” que pega o texto do elemento selecionado, e o “`get_text()`” que pega o texto do elemento e o de seus filhos.

Finalizando o conteúdo, o instrutor mostra o acesso por meio de atributos, utilizando como exemplo a tag “a” que tem um link, para conseguir pegar somente o link é feito ‘`link[“href”].x`’

Na figura 1, é apresentado um exemplo real de como pode ser utilizado web scraping.

Figura 1



3. Conclusão

O scrapping é utilizado para obter dados através da web, o que ajuda muito na criação de datasets e obtenção de dados para pipelines de ciência de dados e treinos de Machine Learning. Ele ajuda na utilização de dados que estão em sites e por meio do scraping virarem treinos de ML, ou análises para alguma empresa.